企业级富容器技术 PouchContainer 详解

孙宏亮 阿里巴巴 2018.03.24

Agenda

- ・阿里集团容器现状
- · PouchContainer企业级技术优势
- · PouchContainer的开源发展

PART1

阿里集团容器现状

阿里集团容器现状

规模:

- 覆盖集团大部分BU
- 2017年双11百万级容器
- 在线业务100%容器化

覆盖场景:

- 运行模式
- 编程语言
- 技术栈

覆盖业务:

- 蚂蚁&交易&中间件
- B2B/CBU/ICBU/1688/村淘
- 合一集团(优酷)
- 菜鸟&高德&UC(接入中)
- 集团测试环境
- 广告(阿里妈妈)
- 阿里云专有云输出
- •

阿里集团容器现状

- 本意育儿袋,隐喻贴身呵护应用
- 始于2011年
- 基于LXC
- 阿里内部容器技术产品,并于当年上线
- 2015年初开始吸收Docker镜像功能
- 容器结合阿里内核,大幅提高隔离性
- ◆ 大规模部署于阿里集团内部




PouchContainer演进之路

- 容器的要素--阿里内部运维和应用视角
 - 有独立IP
 - 能够ssh登陆
 - 独立的的文件系统
 - 资源隔离—使用量和可见性

- 手工Hack实现容器要素
 - ・虚拟网卡 / 网桥
 - sshd
 - Chroot (pivot_root)
 - CGroup , Namespace




- · 引入LXC(<u>Linux Container</u>)
- 内核可见性隔离Patch
- 内核磁盘空间配额Patch




PART2

PouchContainer技术优势

PouchContainer 技术优势



PouchContainer 生态架构 CNI **Pod** kubelet namespace 编排 **Ouch** workflow **8** Pouch runC cri-manager (RPC) container d SWARM runW con ainer API 容器 isolation **lxcfs** pouchd workflow namespace bridge container API libnetwork Sigma macvlan ultron container P₂P storage Dragonfly ceph/pangu 容器引擎 编排调度 容器运行时




丰富的隔离性

- 传统容器的隔离维度: namesapce, cgroup
- 更优的容器可见性隔离:内核patch, lxcfs
- 额外隔离维度:磁盘,网络等:diskquota
- 基于Hypervisor的强容器隔离
 - runV
 - clear container

资源可见性隔离 LXCFS

- ・使用场景
 - · Java应用判断资源大小动态分配堆栈大小,莫名OOM
 - · Java中间件通过CPU核来创建线程数

/proc



资源可见性隔离 LXCFS

不使用LXCFS



使用LXCFS

```
$ pouch run -m 200m --enableLxcfs registry.hub.docker.com/library/ubuntu:16.04 free -h
                                                 shared buff/cache
              total
                           used
                                       free
                                                                     available
Mem:
               200M
                           876K
                                       199M
                                                   3.3M
                                                                12K
                                                                           199M
               2.0G
                             0B
                                       2.0G
Swap:
```

https://github.com/alibaba/pouch/blob/master/docs/features/pouch_with_lxcfs.md

Diskquota容器磁盘限额

DiskQuota是一种限制文件系统磁盘空间使用的技术;

控制磁盘使用量的功能(Volume/容器rootfs);

基于块设备的方式是可以直接控制磁盘的使用量(size/inode);

DiskQuota功能在内核支持的版本情况:

	user/group quota	project quota
ext4	> 2.6	> 4.5
xfs	> 2.6	> 3.10

Diskquota容器磁盘限额

1. rootfs设置quota,通过--disk-quota的参数指定


# pouch run -ti	-disk-quota 10g	registry.h	nub.docker	r.com/library/busybox:latest df -h
Filesystem	Size	Used Av	/ailable l	<u>Use% Mou</u> nted on
overlay	10.0G	24.0K	10.0G	0% /
tmpfs	64.0M	0	64.0M	0% /dev
shm	64.0M	0	64.0M	0% /dev/shm
tmpfs	64.0M	0	64.0M	0% /run
tmpfs	64.0M	0	64.0M	0% /proc/kcore
tmpfs	64.0M	0	64.0M	0% /proc/timer_list
tmpfs	64.0M	0	64.0M	0% /proc/sched_debug
tmpfs	1.9G	0	1.9G	0% /sys/firmware
tmpfs	1.9G	0	1.9G	0% /proc/scsi

Diskquota容器磁盘限额

2. volume设置quota,通过设置volume size参数指定

```
# pouch volume create -n volume-quota-test -d local -o mount=/data/volume -o size=10g
Name:
              volume-quota t
Scope:
Status:
              map[mount:/data/volume sifter:Default size:10g]
CreatedAt:
              2018-3-24 13:35:08
Driver:
              local
Labels:
              map[]
              /data/volume/volume-quota-test
Mountpoint:
# pouch run -ti -v volume-quota-test:/mnt registry.hub.docker.com/library/busybox:latest df -h
                                     Used Available Use% Mounted on
Filesystem
                           3126
overlay
                                   212.9M
                                               19.6G
                                                       1% /
                          20.9G
                                                       0% /dev
tmpfs
                                               64.0M
                          64.0M
                                         0
shm
                                                       0% /dev/shm
                          64.0M
                                               64.0M
tmpfs
/dev/sdb2
                          10.0G
                                     4.0K
                                               10.0G
                                                       0% /mnt
tmpfs
                                                       <del>0% /proc</del>/kcore
                          04.0M
                                               04.00
tmpfs
                          64.0M
                                                       0% /proc/timer_list
                                         0
                                               64.0M
tmpfs
                          64.0M
                                               64.0M
                                                       0% /proc/sched debug
                                         0
tmpfs
                           1.9G
                                                1.9G
                                                       0% /sys/firmware
tmpfs
                           1.9G
                                                1.9G
                                                       0% /proc/scsi
                                         0
```

Hypervisor-based Container



Hypervisor-based Container


```
$ pouch create --name hypervisor --runtime runv docker.io/library/busybox:latest
container ID: 95c8d52154515e58ab267+3c33e+74++84c901ad77ab18ee6428a1ffac12400d, name: hypervisor
$ pouch ps
             ID
                      Status
                                                                   Runtime
Name
                                Image
hypervisor
                      created
                                docker.io/library/busybox:latest
             95c8d5
                                                                    runv
4945c0
                                docker.io/library/busybox:latest
             4945c0
                      stopped
                                                                    runc
1dad17
             1dad17
                      stopped
                                docker.io/library/busybox:latest
                                                                   runv
fab7ef
             fab7ef
                      created
                                docker.io/library/busybox:latest
                                                                    runv
                                docker.io/library/busybox:latest
505571
             505571
                      stopped
                                                                    runc
```

https://github.com/alibaba/pouch/blob/master/docs/features/pouch_with_runV.md


P2P镜像分发能力







P2P镜像分发能力



P2P镜像分发能力

■传统模式 ■17蜻蜓

总分发量 v.s 镜像分发量



富容器

- 容器内运行init进程, PID=1
- 容器内运行系统服务
- 用户体验如传统 VM
- 极强的应用适配性
- 集团应用100%容器化的重要前提
- 容器内资源多维度隔离(alikernel支持)

https://github.com/alibaba/pouch/blob/master/docs/features/pouch_with_rich_container.md

规模化考验

- 阿里巴巴集团内部大规模场景验证
- 绝大部分BU
- 2016年双11,几十万容器应对超大规模负载
- 2017年容器常规规模达到数十万
- 2017年双11,容器规模达到百万级
- 混部支持

内核兼容性

- 阿里仍存有相当规模的 Linux 2.6.x 内核机器
- 规模效应,放大现有老系统的资产价值
- PouchContainer支持内部所有 Linux 2.6.x 的内核
- 部分支持来源指定系统调用的回避
- 部分支持来源内核补丁


PART3

PouchContainer开源发展

https://github.com/alibaba/pouch

2275 star 43位贡献者 1位协作机器人

文档测试




安装指南: https://github.com/alibaba/pouch/blob/master/INSTALLATION.md

pouchrobot

Label标签 冲突检测 周报生成 文档生成 CI通知集成

分布式协作效率



如何参与 Pouch

- 在你的组织中使用Pouch
- 布道与宣传
- 贡献回你的bug修复、功能扩展以及文档
- 日常贡献 -> maintainer
- 说服你的朋友贡献新科技
- https://github.com/alibaba/pouch/blob/ma
 ster/CONTRIBUTING.md

Q&A

We are hiring!

Email: allensun.shl@alibaba-inc.com

WeChat: shlallen

Thank You